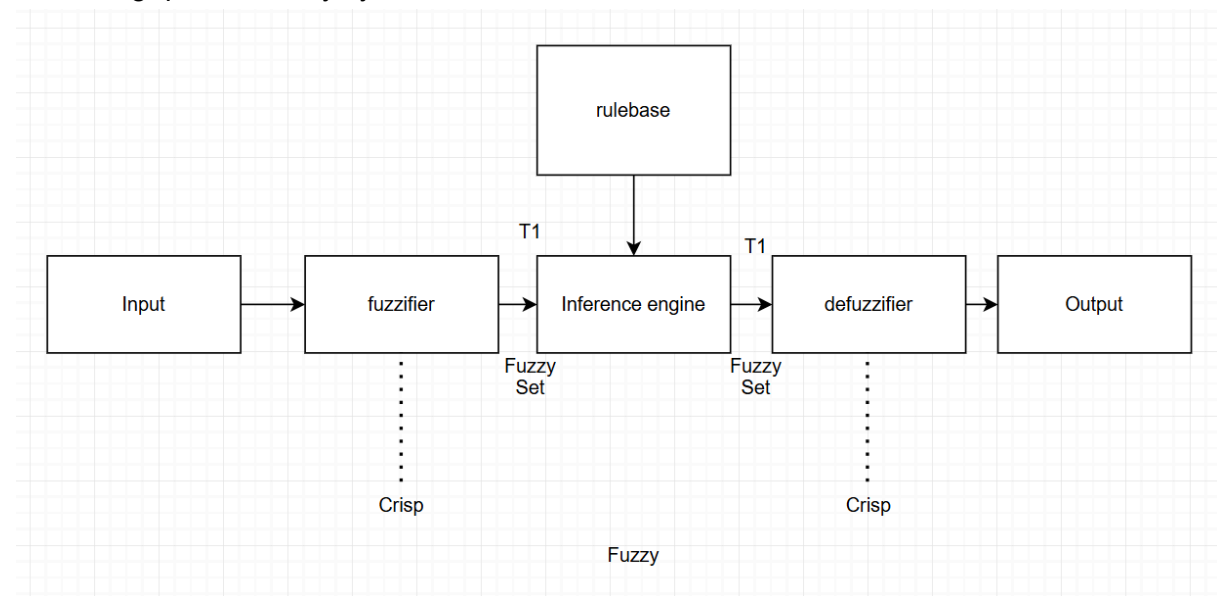


Câu 1:

Ví dụ về fuzzy system:

Áp dụng hệ mờ vào bài toán giữ mức nước an toàn giữa bể nước và hồ nước tránh bị tràn hồ dẫn đến lãng phí tài nguyên. Cách hoạt động giống với công nghệ điều chỉnh của máy bơm tự động.


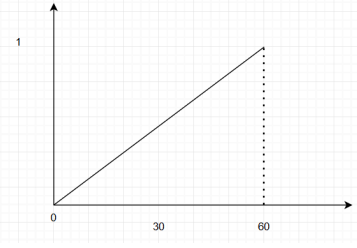

Ta có tổng quan về fuzzy system:



Đối với bài toán giữ mức nước an toàn cho bể nước ta có các biến đầu vào là Mức nước hồ (lake amount) và Mức nước bể (tank amount). Biến đầu ra là Mức điều chỉnh sức bơm (Accelerate). Từ đó ta suy ra các tập luật mờ:

	Bể đầy	Bể lưng	Bể cạn
Hồ đầy	0	0	0
Hồ lưng	Bơm vừa	Bơm vừa	0
Hồ cạn	Bơm lâu	Bơm vừa	0

Lake amount	Tank amount	Accelerate
Lưng	Đầy	<p>Bơm vừa</p>

Lưng	Lưng	 <p>Bơm vừa</p>
Cạn	Đầy	 <p>Bơm lâu</p>
Cạn	Lưng	 <p>Bơm vừa</p>

Tập luật mờ ứng với các trường hợp đầu vào để tính toán và điều chỉnh sức bơm cho máy bơm phù hợp khi nhận được giá trị đầu vào. Các giá trị cạn, lưng, đầy được mờ hóa từ các giá trị % mức nước: 20% - Cạn, 50% - Lưng, 100% - Đầy. Các giá trị đầu ra điều chỉnh thời gian bơm là 30 phút - Bơm vừa, 60 phút - Bơm lâu.

Các luật được biểu diễn dưới dạng text:

- IF Lake amount = Lưng AND Tank amount = Đầy THEN Accelerate = Bơm vừa.
- IF Lake amount = Lưng AND Tank amount = Lưng THEN Accelerate = Bơm vừa.
- IF Lake amount = Cạn AND Tank amount = Đầy THEN Accelerate = Bơm lâu.
- IF Lake amount = Cạn AND Tank amount = Lưng THEN Accelerate = Bơm vừa.

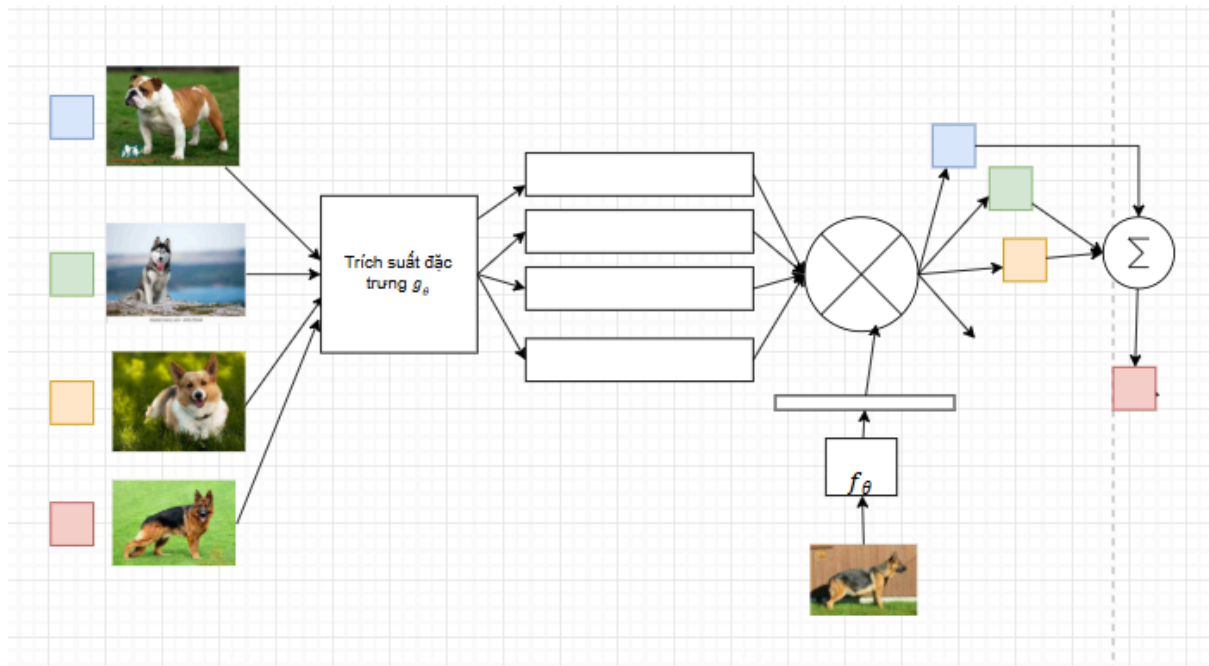
Câu 2:

Ví dụ few-short learning:


Áp dụng vào nhận dạng giống chó:

Đầu vào của mô hình gồm 2 tập support set và query set. Support set là tập ảnh có nhãn gồm 1 lớp vài mẫu. Query set là tập ảnh chưa có nhãn được đưa vào mạng CNN để trích xuất đặc trưng. Cả 2 tập đầu vào được trích xuất đặc trưng bằng CNN. Sự so sánh các đặc trưng tương đồng ứng dụng bằng cách tính Cosine similarity. Sau đó các nhãn được dự bằng softmax. Bộ tổng tổng hợp các sự tương đồng thông qua chỉ số cosine để quyết định lớp cho tập query.

Hàm mất mát là hàm Cross- entropy Loss sau khi tính được độ tương đồng có thể dùng softmax để chuyển cosine thành xác suất rồi áp dụng.



Câu 3:



Đầu tiên, các câu tiếng Anh và tiếng Pháp được mã hóa thành các chuỗi số nguyên (token ID) thông qua một từ điển (vocab) được tạo thủ công. Mỗi token được chuyển thành vector liên tục có kích thước 64 chiều bằng lớp nn.Embedding. Vì Transformer không xử lý dữ liệu tuần tự như RNN nên ta bổ sung thông tin vị trí bằng Positional Encoding — ở đây được tính bằng hàm sin và cos để gán cho mỗi vị trí một vector đặc trưng, giúp mô hình hiểu

được thứ tự từ trong câu. Sau đó, các vector này được đưa vào kiến trúc Transformer gồm 2 lớp Encoder và 2 lớp Decoder, mỗi lớp có 4 đầu Attention song song (multi-head attention) và mạng feed-forward ẩn 128 neuron. Phần Encoder học biểu diễn ngữ nghĩa của câu nguồn (tiếng Anh), còn Decoder sinh dần từng từ của câu đích (tiếng Pháp) dựa trên ngữ cảnh và những từ đã sinh ra trước đó. Đầu ra cuối cùng của Transformer là các vector được tuyến tính hóa qua `fc_out` để cho ra xác suất phân phối trên toàn bộ từ vựng; token có xác suất cao nhất sẽ được chọn làm từ kế tiếp trong câu dịch. Trong quá trình huấn luyện, mô hình được tối ưu bằng hàm mất mát CrossEntropyLoss, so sánh xác suất dự đoán của mỗi token với token thật trong câu đích, đồng thời bỏ qua các token `<pad>` để tránh ảnh hưởng từ phần đệm chuỗi. Input của mô hình là hai tensor: `src` (chuỗi tiếng Anh) và `tgt` (chuỗi tiếng Pháp đã dịch được một phần), còn output là xác suất của token kế tiếp trong chuỗi đích. Nhờ cấu trúc Attention, mô hình học được quan hệ giữa các từ trong cả câu nguồn lẫn câu đích, cho phép sinh ra bản dịch tương đối chính xác sau khi huấn luyện ngắn.